

191220133 徐思源 本科生 计算机系 计算机系统.

6.1.(a) 设  $X$  是  $m \times n$  的矩阵, 列秩为  $r$ , 因此  $X$  的列空间维数为  $r$ , 令  $C_1, C_2 \dots C_r$  是  $X$  列空间的基, 构成  $m \times r$  的矩阵  $C = [C_1, C_2 \dots C_r]$ .

∴  $A$  的列向量是  $C$  列向量线性组合构成的,

∴ 存在一个矩阵  $R (r \times n)$  使  $A = CR$ .

∴  $A$  的行向量是  $R$  行向量的线性组合

∴  $A$  的行秩  $\leq R$  的行秩  $\leq r = A$  的列秩.

$$A$$
 的列秩  $= A^T$  行秩  $\leq A^T$  列秩  $= A$  的行秩. ①

$$A$$
 的行秩  $= A^T$  行秩  $\leq A^T$  列秩  $= A$  的列秩. ②

由①②知  $A$  的行秩等于列秩 ∴  $\text{rank}(X) = \text{rank}(X^T)$ .

(b) ∵  $\text{rank}(A^T) = \text{rank}(A)$  且  $\text{rank}(A^T) \leq n$   $\text{rank}(A) \leq m$ .

∴  $\text{rank}(A) \leq \min(m, n)$

(c) 类似(a)中  $X$  的基是  $a_1 \dots a_s$ ,  $Y$  的基为  $b_1 \dots b_t$

∴  $X$  行向量由  $a_1 \dots a_s$  线性组合,  $Y$  行向量由  $b_1 \dots b_t$  线性组合.

易知  $X+Y$  由  $a_1 \dots a_s, b_1 \dots b_t$  线性组合. ∴  $\text{rank}(X+Y) \leq s+t = \text{rank}(X)+\text{rank}(Y)$ .

(d) 类似(c)中,  $XY$  中的行向量是  $a_i Y \sim a_s Y$  或  $X b_1 \sim X b_t$  (两种表示).

∴  $\text{rank}(XY) \leq \min(\text{rank}(X), \text{rank}(Y))$ .

(e) ∵  $\text{rank}(X) = \text{rank}(X^T)$ . 不失一般性, 令  $m \leq n$ .

∴  $\text{rank}(X) = \text{rank}(X^T) = m$ .  $X$  行满秩,  $X^T$  列满秩.

∴  $X, X^T$  可逆, ∴  $X = XX^T(X^T)^{-1} \leq \text{rank}(XX^T)$ .

[回] 且  $\text{rank}(XX^T) \leq m = \text{rank}(X)$ .

∴  $\text{rank}(X) = \text{rank}(XX^T)$  同理可得  $\text{rank}(X) = \text{rank}(XX^T) = \text{rank}(X^TX)$ .

(f)  $\text{rank}(XX^T) \leq \min(\text{rank}(X), \text{rank}(X^T)) = 1$ .  $XX^T$  只有一列.

∴ 存在可逆矩阵  $Y$  使  $Y^{-1}(XX^T)Y = I$  (对角矩阵非零值系数).

∴  $\text{rank}(X) = \text{rank}(I) = \text{特征值数}$ .

6.4.(a) 直接计算可知正确

(b) 保留  $v$  前  $k$  位, 之后变为 0.

(c)  $A$  变成一个上三角矩阵.

(d) 是知  $\det(M_k) = \det(M_{k(1,1)}) + 0 \cdot \det(M_{k(1,2)}) \dots = 1$  (下三角)

$$L = M_m M_{m-1} \dots M_1 = \begin{pmatrix} -\frac{v_1}{v_1} & & & & 0 \\ & \ddots & & & \\ & & \ddots & & \\ & & & \ddots & \\ -\frac{v_n}{v_1} & & \frac{v_n}{v_{n-1}} & & 1 \end{pmatrix}$$

$L$  为下三角  $\det L = |x_1 \dots x_n| = 1$   
 $(\det(M_k) = 1)$ .

(e) 由(d)知存在  $M_1 \dots M_{n-1}$  使  $M_{n-1} \dots M_1 A = U$ , 其中  $U$  为上三角矩阵。  
 $M_{n-1} \dots M_1$  可逆  $\therefore A = LU$  ( $L = (M_{n-1} \dots M_1)^{-1}$ ).  
 系  $A$  非奇异, 有唯一组  $U^T$  使  $A = XY = LU$   
 $\Rightarrow L^{-1}X = UY^{-1}$

上<sup>左</sup>下<sup>右</sup>  $\Rightarrow$   $X$  是单位矩阵  
 即  $L^{-1}X = U^{-1}Y^{-1}$  异值  $\therefore$  是唯一的.

(f) 由(e)知  $A$  有唯一的  $LU$  分解, 易知  $L$  对角线为 1.

$$\text{令 } U = DX \quad D = \begin{pmatrix} u_{11} & & \\ & \ddots & \\ & & u_{nn} \end{pmatrix} \quad X = \begin{pmatrix} 1 & \frac{u_{12}}{u_{11}} & \cdots & \frac{u_{1n}}{u_{11}} \\ & 1 & & \\ & & \ddots & \\ & & & 1 \end{pmatrix}.$$

$$AT = A \quad \therefore A^T = (LDX)^T = X^T D^T L^T = U^T D^T L^T = LDL^T = A.$$

$$\text{由(e)得 } -1 \text{ 和 } X = L^T \quad \therefore A = LDL^T.$$

$$(g) \text{ 由(f)知 } A = LDL^T. \text{ 设 } D = \begin{pmatrix} d_1 & & \\ & \ddots & \\ & & d_n \end{pmatrix} \quad \text{则 } \sqrt{D} = \begin{pmatrix} \sqrt{d_1} & & \\ & \ddots & \\ & & \sqrt{d_n} \end{pmatrix}. \quad (\text{因为 } \sqrt{D} \cdot \sqrt{D} = D).$$

$$\therefore A = LDL^T = L\sqrt{D}(L\sqrt{D})^T$$

$$\text{令 } G = L\sqrt{D} \quad \text{则 } A = GG^T$$

$\therefore$  由iris cholesky 分解也唯一.

下一节在github 下载源码并 make 编译:

```
miracle@ubuntu:~/Desktop/libsvm-master$ make
g++ -Wall -fPIC -O3 -c svm.cpp
g++ -Wall -fPIC -O3 -c svm-train.cpp -o svm-train -lm
g++ -Wall -fPIC -O3 -c svm-predict.cpp -o svm-predict -lm
g++ -Wall -fPIC -O3 -c svm-scale.c -o svm-scale
miracle@ubuntu:~/Desktop/libsvm-master$
```

- (b) i) Accuracy = 66.92% ( $2677/4000$ )  
 ii) Accuracy = 95.40% ( $3871/4000$ )  
 iii) Accuracy = 95.67% ( $3827/4000$ )  
 iv) Accuracy = 70.47% ( $2819/4000$ ).  
 v) Accuracy = 96.87% ( $3875/4000$ )

(c) 有不平衡数据集 svmguide3.

默认参数下 Accuracy = 2.4390%.

提高对频率较低类的权重, 如调整为 2.5 和 0.6, 则 Accuracy 上升至 75.6098%.

7<sup>2</sup> (a)  $K_{H2}(x, y) = \min(x_i y_i)$  映射为  $\phi$   $\therefore K_{H2}(x, y) = \sum_{i=1}^d \min(x_i y_i) = \phi_1 + \dots + \phi_d$ .  
 即存在一个映射  $f(x, y) = \phi_1 + \dots + \phi_d$  合法.

(b)  $\because X$  可以通过行列变换和  $y$  互换实现  $\therefore Y$  是(半)正定的  $X$  (半)正定.

(c) 设  $P = \begin{pmatrix} 1 & -1 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & -1 \end{pmatrix}$   $\therefore P^T X P = \begin{pmatrix} x_1 & x_2 & x_3 & 0 \\ 0 & x_2 & x_3 & 0 \\ 0 & 0 & x_3 & 0 \end{pmatrix} = I$

$P^T X P$  是半正定的  $\therefore X$  是半正定的 ( $\because P$  可逆  $\therefore X = (P^T)^{-1} I P^{-1} \rightarrow L D L^T$  的解).

(d) 设  $x_i \leq y_i$  是真  $\therefore x_i \leq \frac{2x_i y_i}{y_i + y_i} \leq \frac{2x_i y_i}{x_i + y_i}$



$\therefore K_{H2}(x, y) = \sum_{i=1}^d \min(x_i y_i) \leq \sum_{i=1}^d \frac{2x_i y_i}{x_i + y_i} = K_H(x, y)$ .

(e) 令  $f(x) = \sqrt{x}$   
 $\therefore K_{H3} = \sum_{i=1}^d f(x_i) f(y_i) = f(x)^T f(y)$ .  $\therefore$  是合法的. 映射为  $f$

易知  $\frac{2x_i y_i}{x_i + y_i} \leq \frac{2x_i y_i}{2\sqrt{x_i y_i}} = \sqrt{x_i y_i}$ .

$\therefore K_H^2(x, y) \leq K_{H3}(x, y)$ .

(f) 假设函数分布图可以用直方图表示.



可以将解为取两个直方图  
的交集 (在图上画了).  
 ↑

度量不一定相同

9<sup>2</sup> (a) 若  $S_i$  是  $i$  最近邻  $k$  的样本的集合, 则  $e_i = \left\| \mathbf{x}_i - \sum_{S \in S_i} w_i s_i x_S \right\|^2 \quad \sum_{S \in S_i} w_i = 1$

$$\sum_{i=1}^n e_i = \sum_{i=1}^n \left\| \sum_{S \in S_i} w_i s_i x_S - \sum_{S \in S_i} w_i s_i x_S \right\|^2$$

$$= \sum_{i=1}^n w_i^T \left( \sum_{S \in S_i} (x_i - x_S) (x_i - x_S)^T w_i \right)$$

$$\sum_i \sum_{j \in S_i} (x_i - x_j) (x_i - x_j)^T w_i \quad \text{且} \quad \sum_{i=1}^n e_i = \sum_{i=1}^n w_i^T y_i w_i$$

$$\therefore \sum_{S \in S_i} w_j = w_i \sum_{j \in S_i} 1 = 1. \quad (\Sigma_i \text{ 为全向量})$$

$$\text{拉格朗日函数 } L(w, \lambda) = \sum_{i=1}^n (w_i^T y_i w_i + \lambda_i (w_i^T z_i - 1))$$

对  $w_i$  求导有  $\begin{cases} \lambda_i = -\frac{z_i^T y_i^{-1} z_i}{z_i^T y_i^{-1} z_i} \\ w_i = \frac{y_i^{-1} z_i}{z_i^T y_i^{-1} z_i} \end{cases}$

$$\therefore (w_1, \dots, w_k)^T = \frac{y_i^{-1} z_i}{z_i^T y_i^{-1} z_i} \quad (\text{对 } k \text{ 近邻点})$$

对其他  $i$  有  $w_i = 0$

(b) 稳定不变性:  $\sum_{i=1}^n e_i = \sum_{i=1}^n w_i^T Q (x_i - x_j) (x_i - x_j)^T Q^T w_i$

同样  $y_j = \sum_{s \in S_j} (x_i - x_s) (x_i - x_s)^T$

$$L(w, \lambda) = \sum_{i=1}^n w_i^T y_i Q^T w_i + \lambda_i (w_i^T z_i - 1) \text{ 且 } w_i^T z_i = 1$$

对  $w_i$  求导得  $w_i = \frac{(Q y_i Q^T)^{-1} z_i}{z_i^T (Q y_i Q^T)^{-1} z_i}$

$$\because Q Q^T = I \quad \therefore w_i = \frac{y_i^{-1} z_i}{z_i^T y_i^{-1} z_i} \quad \text{同样有稳定不变性.}$$

即  $\sum_{i=1}^n e_i = \sum_{i=1}^n \|x_i - \sum_{s \in S_i} w_i s c(x_s + t)\|^2 = \sum_{i=1}^n \left\| \sum_{s \in S_i} w_i s c(x_s + t) - \sum_{s \in S_i} w_i s c(x_s) \right\|^2$

$$= \sum_{i=1}^n \left\| \sum_{s \in S_i} w_i (x_i - x_s) \right\|^2 \text{ 和移前 } \sum_{i=1}^n e_i \text{ 相同.}$$

从而  $w_i$  一定相同, 有平移不变性.

缩写:  $\sum_{i=1}^n e_i = \sum_{i=1}^n \|x_i - \sum_{s \in S_i} w_i s c(x_s)\|^2 = \sum_{i=1}^n \left\| \sum_{j=1}^n w_{ij} (x_i - x_j) \right\|^2$   
 $= S^2 \sum_{i=1}^n w_i^T (x_i - x_j) (x_i - x_j)^T w_j = S^2 \sum_{i=1}^n w_i^T Y_i w_i$

$$\therefore L(w, \lambda) = S \sum_{i=1}^n w_i^T Y_i w_i + \lambda_i (w_i^T z_i - 1) \text{ 且 } w_i^T z_i - 1 = 0$$

求得  $w_i = \frac{y_i^{-1} z_i}{z_i^T y_i^{-1} z_i}$   $\therefore$  有缩放不变性.

(c)  $\sum \|x_i - \sum w_j x_{ij}\|^2$  可以通过使得  $w_j$  可以用  $x_j$  的样本近似表示.

2.  $M_j$  保存了  $x_j$  和其 k 近邻样本之间的几何关系. 而  $x_j$  映射到  $d$  维空间时,  $\sum \|y_i - \sum w_j y_{ij}\|^2$  会使得  $y_j$  和对应的  $y_{ij}$  (k 近邻) 之间也有线性表示. 保留了局部几何关系. 第一个约束到中心化, 第二个为了防止  $y_j$  距离小的点离中心会一直变小, 失去多样性.

平移、缩放被消去.

平移不消去会不在中心, 缩放会影响参数过大.

$$(d) W = (w_1 \cdots w_m)^T$$

$$\therefore \sum_{j=1}^n \|y_i - \sum_{j=1}^m w_j y_{ij}\|^2. \quad ①$$

$$= \sum_{j=1}^m \sum_{i=1}^n w_j^T (y_i - y_{ij}) (y_i - y_{ij})^T w_j$$

$$\because \sum_{i=1}^n y_i y_i^T = I \quad \text{且 } M = (I - w)^T (I - w)$$

$$\therefore ① = \sum_{j=1}^m \sum_{i=1}^n M_{ij} y_i^T y_{ij}$$

$$(e) \left\{ \begin{array}{l} \sum_{j=1}^m \sum_{i=1}^n M_{ij} y_i^T y_{ij} = \text{tr}(Y^T M Y^T), \\ \sum_{i=1}^n y_i y_i^T = I. \end{array} \right.$$

$$\text{令 } L(Y, \lambda) = \text{tr}(Y^T M Y^T + \lambda(Y^T Y - I)).$$

求导可知  $M = (Y^T)^{-1} \lambda Y^T$   $\because \lambda > 0 \therefore M$  是半正定的.

$$\uparrow Y^T Y = I \text{ 知 } Y \text{ 可逆}$$

$$\therefore M \cdot I = (I - w)^T (I - w) \cdot I$$

$$= (I - w)^T (I - I - w \cdot I) = 0$$

$$\therefore \lambda = 0 \text{ 持久问题!}$$