

Mathematical basis

-PROMISE-

Tuesday 5th April, 2022


1 线性代数

1.1 向量 vector

- 对于向量 $x = (x_1 \ x_2, \dots, x_d)^d \in \mathbb{R}^d$
- 内积: $x^T y = y^T x = \sum_i x_i y_i$
- 向量长度 $\|x\| = \sqrt{x^T x}$, $\|x\|^2 = x^T x$
- $\|x\| = 1$ 的时候, x 是单位向量
- 正交: $x^T y = 0$ 时, x, y 互相垂直

1.2 内积, 角度, 投影

- $\|x\|$ 为向量长度, $\frac{x}{\|x\|}$ 为向量方向
- 向量夹角: $x^T y = \|x\| \cdot \|y\| \cdot \cos \theta$, $\|x^T y\| \leq \|x\| \cdot \|y\|$
- x 在 y 上的投影 (projection):
方向: $\frac{y}{\|y\|}$, 长度: $\|x\| \cos \theta = \|x\| \frac{x^T y}{\|x\| \cdot \|y\|} = \frac{x^T y}{\|y\|}$
- 投影:
 $proj_y x = \frac{x^T y}{\|y\|^2} y$, $proj_y x \perp z$, $proj_y x + z = x$



1.3 柯西-施瓦茨不等式

1.3.1 Cauchy's inequality

- $(\sum_{k=1}^n a_k b_k)^2 \leq (\sum_{k=1}^n a_k^2)(\sum_{k=1}^n b_k^2)$
等号当且仅当存在固定实数 c , 使得 $\forall k, a_k = cb_k$

1.3.2 Schwarz's Inequality

- $[\int_a^b f(x)g(x)dx]^2 \leq [\int_a^b f(x)^2 dx][\int_a^b g(x)^2 dx]$
等号当且仅当存在固定实数 c , 使得 $\forall x \in [a, b], f(x) = cg(x)$

1.4 矩阵

- 矩阵 $m \times n$ 的矩阵, m 行 n 列
 $m=n$ 时为方阵
对角阵是只有对角线非零的方阵, 其中对角线全是 1 就是单位阵

I_n T

- 方阵行列式的值
 $|X| = |X^T|$
 $|XY| = |X||Y|$
 $|\lambda X| = \lambda^n |X| (X: n \times n)$
- 逆矩阵
 $|X| \neq 0$ 则 X 可逆 ($|X|$ 写作 $\det(X)$)
 $XX^{-1} = X^{-1}X = I_n$
 $(X^{-1})^{-1} = X, (\lambda X)^{-1} = \frac{1}{\lambda} X^{-1}$
 $(XY)^{-1} = Y^{-1}X^{-1}, (X^{-1})^T = (X^T)^{-1}$

1.5 方阵特征值

- $Ax = \lambda x$ λ x
特征值和对角线的关系: $\sum_{i=1}^n a_{ii} = \sum_{i=1}^n \lambda_i, \det(A) = \prod_{i=1}^n \lambda_i$
方阵的迹 (trace): $tr(A) = \sum_{i=1}^n a_{ii} = ??, tr(AB) = tr(BA)$

1.6 实对称矩阵

- 矩阵中每一项都是实数

特征值都是实数，特征向量都是实向量

特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$

对应的特征向量记为 $\xi_1, \xi_2, \dots, \xi_n$

特征向量互相垂直: $\xi_i^T \xi_j = 0 (i \neq j)$

$E = [\xi_1 \xi_2 \dots \xi_n] \quad \text{rank}(E) = n$

1.7 实对称矩阵

- $X = \sum_{i=1}^n \lambda_i \xi_i \xi_i^T$

属于矩阵的谱分布，约定 $\|\xi_i\| = 1$ ，则 E 实正交矩阵

$X = E \Lambda E^T, \quad \Lambda_{ii} = \lambda_i$

$EE^T = E^T E = I$

1.8 正定，半正定

- 对称矩阵 A 是正定的当且仅当：

$\forall x \neq 0, x^T A x = \sum_{i,j} x_i x_j A_{ij} > 0$, 此时特征值全是正数

$\forall x \neq 0, x^T A x = \sum_{i,j} x_i x_j A_{ij} \geq 0$ 则 A 为半正定

记为 $A \succ 0$ 或 $A \succcurlyeq 0$

常用到二次型: $x^T A x$

1.9 矩阵求导

- 导数存在的时候：

$\frac{\partial \mathbf{a}}{\partial x}$ 是一个向量, $(\frac{\partial \mathbf{a}}{\partial x})_i = \frac{\partial a_i}{\partial x}$

对于矩阵 $(\frac{\partial A}{\partial x})_{ij} = \frac{\partial A_{ij}}{\partial x}$

$(\frac{\partial x}{\partial \mathbf{a}})_i = \frac{\partial x}{\partial a_i}, (\frac{\partial x}{\partial A})_{ij} = \frac{\partial x}{\partial A_{ij}}, (\frac{\partial \mathbf{a}}{\partial \mathbf{x}})_{ij} = \frac{\partial a_i}{\partial x_j}$

用 Matrix Cookbook 查表

2 概率论

2.1 概率密度函数，分布函数

- PDF 和 CDF 的关系: $p(x) = F'(x)$

2.2 联合、条件分布、变换

- 联合: $P(X = x), p(x) \geq 0 \int p(x)dx = 1$
- 条件: $p(x, y) = p(y)p(x|y), p(x) = \int_y p(x, y)dy$ (边界分布)
- 假设 $x = g(y), p_Y(y) = p_X(x)|\frac{dx}{dy}| = p_X(g(y))|g'(y)|$

2.3 期望和方差

- 常规的省略, 条件期望: $E(f(x)|Y = y) = \sum_x f(x) \cdot p(x|y)$

2.4 估计均值和协方差矩阵

- 训练样本: x_1, x_2, \dots, x_n
均值估计 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Covariance 估计: $Cov(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T$
无偏估计: $Cov(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T$

2.5 两随机变量的独立、相关

- $(X, Y) = (x, y)$ 则 X, Y 互相独立
 $cov(X, Y) = E[(X - EX)(Y - EY)] = EX + EY - EXY$
 $\rho_{XY} = \frac{cov(X, Y)}{\sqrt{Var(X)Var(Y)}} \rho_{XY} = 0$ 时为不相关, $\rho_{XY} \pm 1$,
• 独立保证一定不相关, 但不相关不一定独立

2.6 正态分布 (高斯分布)

- 一维: $p(x) = (2\pi)^{-\frac{1}{2}} (\sigma^2)^{-\frac{1}{2}} \exp(-\frac{1}{2\sigma^2}(x-\mu)^2)$
多维: $p(x) = (2\pi)^{-\frac{D}{2}} |\Sigma|^{-\frac{1}{2}} \exp(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu))$, 其中 D : 维数, Σ : 协方差矩阵, μ : 均值
• 正态分布中不相关等价于独立
两个正态分布的加权和: $aX + bY$ 也是正态分布
条件分布: $x_a|x_b$ 也是高斯分布
边缘分布: $p(x_a) = \int p(x_a, x_b)dx_b$ 也是正态分布